

Coleta e estudo da Wiki Vote para contenção de propagação

Kauê de Oliveira Silva

GCC118 Programação Matemática • Semestre 2026/2

Etapa 1 Coleta e estudo dos dados • 8 de outubro de 2026

1 Objetivo e escopo

A análise caracteriza a rede Wiki-Vote quanto ao tamanho, à qualidade dos registros e à viabilidade de uso no problema de contenção de propagação por remoção de vértices. A auditoria identificou 7.115 vértices e 103.689 arcos dirigidos, sem linhas inválidas, duplicatas ou laços. A base permite construir instâncias verificáveis, mas a direção dos arcos e a escolha dos vértices iniciais afetam fortemente a propagação.

O problema considera uma rede $G = (V, A)$, um conjunto inicial S e a remoção de exatamente c vértices fora de S . A propagação é medida pelo número de vértices alcançáveis a partir de S após a remoção, incluindo os próprios vértices de S . Nesta etapa foram executadas análises estruturais e de alcançabilidade sem intervenção; resultados de solver e de heurísticas serão estudados nas etapas seguintes.

2 Fonte e significado dos dados

O arquivo Wiki-Vote.txt.gz foi obtido do SNAP em 08/10/2026 [1]. Cada ID identifica um usuário; um arco $i \rightarrow j$ registra um voto de i em j em eleições para administradores da Wikipédia. A cobertura vai até janeiro de 2008. A representação adotada é um grafo dirigido, simples e sem pesos, mantendo os IDs originais. Os registros descrevem votação, não eventos observados de contágio: o processo de propagação aplicado à topologia é uma hipótese experimental.

Característica	Valor verificado
Vértices distintos	7.115
Registros e arcos distintos	103.689
Arquivo comprimido	290.339 bytes
Conteúdo descomprimido	1.095.061 bytes
Densidade dirigida sem laços	0,00204854 (0,2049%)

A densidade foi calculada como $|A| / (|V| \times (|V| - 1))$. A base original foi preservada. A identificação do arquivo e os comandos de reprodução constam na seção 8.

3 Preparação e qualidade dos registros

O script `analisar.py` descomprime o arquivo, ignora apenas as quatro linhas de comentário e valida duas colunas de IDs inteiros não negativos em cada registro. A auditoria compara registros com pares dirigidos distintos e verifica laços. A representação admite a remoção de duplicatas e laços caso existam; no arquivo analisado essas operações não alteraram a base.

Verificação	Resultado	Decisão
Registros válidos	103.689	Todos preservados
Linhas inválidas	0	Nenhuma exclusão por erro
Duplicatas excedentes	0	Nenhuma deduplicação efetiva
Laços $i \rightarrow i$	0	Nenhuma remoção efetiva
Pares recíprocos	2.927	Manter os dois sentidos
Arcos em pares recíprocos	5.854	São relações distintas

O cabeçalho contém uma observação genérica sobre pares sem orientação, mas o arquivo possui 2.927 pares com ambos os sentidos. Por isso, a análise segue a definição dirigida de origem e destino, sem fundir $i \rightarrow j$ e $j \rightarrow i$. A ausência de erros nas duas colunas não garante completude histórica dos votos. A lista de arcos também não permite recuperar usuários isolados ausentes dos registros.

4 Componentes e conectividade

Medida	Resultado
Componentes fracamente conexas	24
Maior componente fraca	7.066 vértices e 103.663 arcos
Demais componentes fracas	3 de tamanho 3 e 20 de tamanho 2
Componentes fortemente conexas	5.816
Maior componente forte	1.300 vértices e 39.456 arcos
Demais componentes fortes	5.815 de tamanho 1

Uma componente fraca conecta vértices ao ignorar a orientação; uma componente forte exige caminhos dirigidos nos dois sentidos. A maior componente fraca reúne 99,31% dos vértices, enquanto a maior forte reúne 18,27%. Portanto, quase toda a rede pertence ao mesmo conjunto conectado sem orientação, mas isso não implica que uma origem possa alcançar toda a rede.

As contagens recalculadas coincidem com a tabela publicada pelo SNAP. O texto descritivo da página apresenta números que coincidem com a maior componente fraca, enquanto a tabela e o cabeçalho do arquivo descrevem a rede completa. Esta análise usa a rede completa como referência e informa os recortes separadamente.

5 Distribuição dos graus

Os graus foram calculados separadamente: entrada conta arcos recebidos e saída conta arcos emitidos. Os percentis usam interpolação linear sobre os graus ordenados; o desvio informado é populacional. Os IDs são identificadores, não variáveis numéricas de interesse estatístico.

Estatística	Entrada	Saída
Mínimo	0	0
Mediana	0	2
Média	14,57	14,57
Percentil 75	13	9
Percentil 95	76	75
Máximo	457	893
Desvio populacional	31,73	42,28
Vértices com grau zero	4.734	1.005




Figura 1. Distribuições acumuladas complementares dos graus. O eixo vertical usa todos os 7.115 vértices como denominador; graus zero foram omitidos apenas do eixo horizontal logarítmico. Fonte: resultados/graus.csv, recalculado nesta análise.

A média de 14,57 supera a mediana de saída de 2 e a mediana de entrada de 0, evidenciando concentração das ligações. Os cinco maiores graus de saída são dos IDs 2565 (893), 766 (773), 11 (743), 457 (732) e 2688 (618). Esse ranking caracteriza a topologia; não demonstra que esses vértices sejam as melhores escolhas para remoção.

Há 1.005 vértices sem saída, aproximadamente 14,13% da rede. Quando S contém apenas um desses vértices, a propagação alcança somente a própria origem. A presença de 4.734 vértices sem entrada também limita quais usuários podem ser atingidos a partir de outras origens. Essas assimetrias justificam estratificar os cenários iniciais.

6 Diagnóstico de alcançabilidade inicial

Foram calculados seis cenários sem remoção ($c = 0$), por busca em largura dirigida. O primeiro critério usa os maiores graus de saída, com desempate pelo menor ID. O segundo usa `random.Random(42).sample` sobre a lista ordenada de IDs. Em cada critério, os conjuntos de tamanho 1, 3 e 5 são prefixos da mesma seleção, permitindo verificar monotonicidade ao adicionar origens.

Critério	Conjunto inicial S	Alcançados
Maior saída	{2565}	2.316
Maior saída	{2565, 766, 11}	2.320
Maior saída	{2565, 766, 11, 457, 2688}	2.325
Aleatório 42	{5931}	1
Aleatório 42	{5931, 991, 215}	2.317
Aleatório 42	{5931, 991, 215, 6967, 2453}	2.318

A origem 2565 alcança 2.316 vértices, ou 32,55% da rede. Adicionar quatro outras origens com alto grau aumenta a contagem para 2.325. O pequeno aumento indica sobreposição entre os conjuntos alcançáveis desses cinco vértices; não prova redundância para todos os possíveis conjuntos de origens.

O cenário $S = \{5931\}$ alcança apenas um vértice, pois essa origem não tem arcos de saída. Como não se pode remover um vértice de S, a contagem mínima nessa configuração é necessariamente 1. Trata-se de um controle trivial, inadequado como único caso de comparação entre métodos.

Para avaliações posteriores, serão mantidos cenários com alto grau de saída e cenários aleatórios, com sementes documentadas e classificação explícita de casos triviais. Um único sorteio não sustenta conclusões estatísticas sobre todas as origens. Os cenários apresentados diagnosticam a base e não constituem comparação de métodos de contenção.

6 1 Convenções das instâncias

Cada instância deve registrar o grafo, os IDs de S e o orçamento c. Para a seleção de exatamente c vértices removidos, impõe-se $0 \leq c \leq |V| - |S|$. A direção original será mantida e as origens serão protegidas contra remoção. Os IDs de cada recorte ficam disponíveis em CSV, permitindo verificar a correspondência com a rede original.

7 Recortes e viabilidade para otimização

Foram gerados recortes induzidos com 100, 300 e 1.000 vértices. A seleção segue uma ordem BFS a partir do ID 2565, usando a vizinhança sem orientação e visitando vizinhos por ID crescente. A seleção dos vértices usa essa vizinhança apenas para garantir conectividade fraca; os arcos dos recortes preservam os sentidos originais. Os recortes são crescentes e não são apresentados como amostras representativas da rede inteira.

Vértices	Arcos	Densidade	SCCs	Alcançados
100	961	9,71%	47	77
300	6.962	7,76%	100	256
1.000	32.207	3,22%	399	867

Em todos os recortes há uma componente fraca e $S = \{2565\}$. Os orçamentos propostos para testes posteriores são $c \in \{1, 3, 5, 10\}$, todos compatíveis com a quantidade de vértices removíveis. As densidades de 9,71%, 7,76% e 3,22% excedem os 0,20% da rede completa: a seleção perto de um vértice muito conectado concentra ligações. Assim, menor tamanho não garante menor dificuldade para o solver.

A formulação compacta preliminar usa três variáveis por vértice e uma restrição de propagação por arco, além das restrições por vértice e do orçamento. Desconsiderando fixações tratadas como limites das variáveis, o tamanho teórico é de $3|V|$ variáveis e $|A| + |V| + 1$ restrições principais. São dimensões derivadas da formulação, não contagens medidas em um modelo executado.

Instância	Variáveis previstas	Restrições principais
100 vértices	300	1.062
300 vértices	900	7.263
1.000 vértices	3.000	33.208
Rede completa	21.345	110.805

A leitura, a auditoria e a construção dos recortes foram viáveis no ambiente desta execução. O script completo terminou em 0,64 segundo, em Python 3.12.14. Essa medição corresponde a uma execução de caracterização, incluindo escritas auxiliares, e não mede resolução de PLI. A viabilidade do modelo exato será testada começando pelos recortes, com registro de tempo, gap e status.

A Wiki-Vote não aparece entre as seis redes reais da seção 7.1 do artigo-base [2]. Isso sustenta o uso de uma rede distinta daquelas listadas, sem estabelecer ineditismo em toda a literatura. A topologia tem tamanho e assimetrias úteis para o estudo; não há necessidade demonstrada de trocar a base nesta etapa.

8 Reprodução e continuidade

Os dados, o script analisar.py e as tabelas de auditoria acompanham o relatório. A análise usa somente a biblioteca padrão Python. Após extrair o pacote, execute:

```
python3 analisar.py
```

A execução escreve resultados/auditoria.json, graus.csv, componentes.csv, arestas_utilizadas.csv, linhas_invalidas.csv e os CSVs de vértices e arcos dos três recortes. O arquivo de linhas inválidas contém somente o cabeçalho, pois nenhuma linha foi rejeitada. A regeneração da figura e do DOCX usa gerar_relatorio.py, python-docx e matplotlib; essas dependências não são necessárias para reproduzir as contagens.

SHA-256 do arquivo comprimido:

```
7d3e53626e14b8b09fb3b396bece9d481ad606bd64ceab066349ff57d4ada7fc
```

SHA-256 do conteúdo descomprimido:

```
d2afbedf262126f820c6b3dd9f39a6d68e6f5ea839c0508297032ca77578b28a
```

O JSON também registra o checksum do analisador e a versão do Python. A geração dos componentes usa buscas iterativas, incluindo Kosaraju para componentes fortes. Foram verificadas a cobertura dos vértices pelas partições e a igualdade entre o número de arcos e a soma dos graus de cada direção.

8 1 Próximas fases

A etapa de modelagem testará a formulação exata em instâncias crescentes. A fase de métodos incluirá comparações com regras de centralidade e uma metaheurística, conforme a orientação do docente. Como opção de implementação, propõe-se busca local iterada (ILS), com trocas entre vértices removidos e não removidos, perturbação e avaliação por alcançabilidade. Essa opção integra o planejamento e ainda não foi implementada ou avaliada.

9 Conclusão

A Wiki-Vote é adequada como base topológica para experimentos abstratos de contenção de propagação dirigida. A auditoria confirma integridade sintática dos registros e permite construir instâncias reproduzíveis. As principais limitações são a interpretação experimental da propagação, as assimetrias de alcançabilidade e o viés dos recortes BFS. Essas condições devem orientar a escolha de cenários e impedir generalizações a partir de casos triviais ou de uma única amostra.

Referências

[1] SNAP. Wikipedia vote network. Disponível em <https://snap.stanford.edu/data/wiki-Vote.html>. Arquivo Wiki-Vote.txt.gz obtido em 08/10/2026.

[2] AGRA, A.; SAMUCO, J. M. Interdiction Models and Heuristics for Graph Propagation. Networks, 2026. DOI: 10.1002/net.70047. Seção 7.1 e Tabela 1 consultadas em 08/10/2026.

[3] UFLA. GCC118 Programação Matemática. Enunciado do Trabalho Prático, semestre 2026/2, seção 2. Atividade Entrega 2 no Campus Virtual: descrição conferida em 08/10/2026.

[4] MOREIRA, Mayron César de Oliveira. Comentário na proposta da Entrega 1, de 15/09/2026, solicitando inclusão de metaheurística na metodologia. Campus Virtual, consultado em 08/10/2026.